

# 第八章 算法

## 算法概念

### 一. 下降迭代算法

**迭代:** 从一点 $x^{(k)}$ 出发, 按照某种规则 $A$ , 求出后继点 $x^{(k+1)}$ , 用 $k+1$ 代替 $k$ , 重复以上过程, 得到一个解的序列 $\{x^{(k)}\}$ , 若该序列有极限点 $x^*$ , 即

$$\lim_{k \rightarrow \infty} \|x^{(k)} - x^*\| = 0$$

则称它收敛于 $x^*$ 。

**下降:** 在每次迭代中, 后继点处的函数值要有所减少。

## 下降迭代算法的步骤:

1. 选定某一初始点 $x^{(0)}$ , 置 $k = 0$ 。
2. 确定搜索方向 $d^{(k)}$ 。
3. 从 $x^{(k)}$ 出发, 沿方向 $d^{(k)}$ 求步长 $\lambda_k$ , 以产生下一个迭代点 $x^{(k+1)}$ 。
4. 检查 $x^{(k+1)}$ 是否为极小点或近似极小点, 若是, 则停止迭代; 否则, 令 $k := k + 1$ , 返回2。

选取搜索方向是最关键的一步, 各种算法的区别, 主要在于确定搜索方向的方法不同。

确定步长 $\lambda_k$ 的主要方法:

- 1.令它等于某一常数。
- 2.可接受点算法，即只要能使目标函数值下降，可任意选取步长 $\lambda_k$ 。
- 3.基于沿搜索方向使目标函数值下降最多，即沿射线

$$x = x^{(k)} + \lambda d^{(k)}$$

求目标函数 $f(x)$ 的极小

$$f(x^{(k)} + \lambda_k d^{(k)}) = \min_{\lambda} f(x^{(k)} + \lambda d^{(k)}).$$

由于这项工作是求以 $\lambda$ 为变量的一元函数的极小点，故常称这一过程为（最优）一维搜索，这样确定的步长为最佳步长。

**定理:** 设目标函数 $f(x)$ 具有一阶偏导数,  $x^{(k+1)}$ 由下列规则产生:

$$\begin{cases} f(x^{(k)} + \lambda_k d^k) = \min_{\lambda} f(x^{(k)} + \lambda d^k) \\ x^{(k+1)} = x^{(k)} + \lambda_k d^k \end{cases}$$

则有 $\nabla f(x^{(k+1)})^T d^k = 0$ 。

**证明:** 记 $\varphi(\lambda) = f(x^{(k)} + \lambda d^k)$

若 $\lambda_k$ 是最优步长, 则 $\lambda_k$ 为 $\varphi(\lambda)$ 的驻点。

$$\therefore \varphi'(\lambda_k) = 0$$

$$\text{而 } \varphi'(\lambda_k) = \nabla f(x^{(k)} + \lambda_k d^k)^T d^k$$

$$\therefore \nabla f(x^{(k)} + \lambda_k d^k)^T d^k = 0$$

## 二. 算法映射

定义: 给定集合  $X \subset E^n$ , 记其幂集 (即所有子集构成的集合) 为  $2^X$ , 称集值映射  $A: X \rightarrow 2^X$  为一个算法映射 (algorithm mapping).

例: 考虑标准形式的线性规划

$$(LP) \quad \min \{cx \mid Ax = b, x \geq 0\},$$

令  $X = \{x \in \mathbb{R}^n \mid x \text{ 为 } LP \text{ 的基本可行解}\}$ , 若定义算法映射

$A(x) = \{y \in \mathbb{R}^n \mid y \text{ 为 } LP \text{ 的基本可行解, 并且 } y \text{ 和 } x \text{ 的基矩阵是相邻的}\}$ ,


那么对于任意一个基本可行解  $x^{(0)} \in X$ , 迭代格式  $x^{(k+1)} \in A(x^{(k)})$  就生成一个相邻的基本可行解序列。

例： 考虑下列非线性规划：

$$\begin{cases} \min x^2 \\ s.t. \quad x \geq 1. \end{cases}$$

定义算法映射：

$$A(x) = \begin{cases} \left[ 1, \frac{1}{2}(x+1) \right] & x \geq 1; \\ \left[ \frac{1}{2}(x+1), 1 \right] & x < 1. \end{cases}$$



利用算法 $A$ 可以产生不同的点列：

$$\left\{ 3, 2, \frac{3}{2}, \frac{5}{4}, \dots \right\}, \quad \left\{ 3, \frac{3}{2}, \frac{9}{8}, \frac{33}{32}, \dots \right\}, \quad \left\{ 3, \frac{5}{3}, \frac{7}{6}, \frac{25}{24}, \dots \right\}$$

## 解集合

把满足某些条件的点集定义为解集合。当迭代点属于该集合时，停止迭代。

常用的解集合：

$$\Omega = \{\bar{x} \mid \|\nabla f(\bar{x})\| = 0\}$$

$$\Omega = \{\bar{x} \mid \bar{x} \text{ 为 } KKT \text{ 点}\}$$

$$\Omega = \{\bar{x} \mid \bar{x} \in S, f(\bar{x}) \leq b\},$$

其中 $b$ 是某个可接受的目标函数值。

## 下降函数

定义：设 $\Omega \subset X$ 为解集合， $A$ 为 $X$ 上的一个算法， $\alpha(x)$ 是定义在 $X$ 上的连续实函数，若满足

1. 当 $x \notin \Omega$ 且 $y \in A(x)$ 时， $\alpha(y) < \alpha(x)$
2. 当 $x \in \Omega$ 且 $y \in A(x)$ 时， $\alpha(y) \leq \alpha(x)$

则称 $\alpha$ 是关于解集合 $\Omega$ 和算法 $A$ 的下降函数。

一般地，求解非线性规划问题

$$\begin{cases} \min f(x) \\ s.t. \quad x \in S \end{cases}$$

时，通常取 $\|\nabla f(x)\|$ 或 $f(x)$ 为下降函数。



## 闭映射(**closed mapping**)


**定义:**给定两个非空闭集 $X \subset E^m$ 和 $Y \subset E^n$ , 以及一个集值映射 $A: X \rightarrow 2^Y$ , 假设点列 $\{x^{(k)}\}$ 和 $\{y^{(k)}\}$ 满足 $x^{(k)} \in X$ ,  $y^{(k)} \in A(x^{(k)})$ 。若 $x^{(k)} \rightarrow x$ ,  $y^{(k)} \rightarrow y (k \rightarrow +\infty)$ 蕴涵着 $y \in A(x)$ , 则称映射 $A$ 在点 $x \in X$ 处是闭的。若映射 $A$ 在集合 $S \subseteq X$ 上每一点是闭的, 则称 $A$ 在集合 $S$ 上是闭映射。

考虑下列非线性规划：

$$\begin{cases} \min x^2 \\ s.t. \quad x \geq 1. \end{cases}$$

定义算法映射：

$$A(x) = \begin{cases} \left[ 1, \frac{1}{2}(x+1) \right] & x \geq 1; \\ \left[ \frac{1}{2}(x+1), 1 \right] & x < 1. \end{cases}$$



该算法在每一点  $x \in R^1$  都是闭的。

考虑下列非线性规划：

$$\begin{cases} \min x^2 \\ \text{s.t. } x \geq 1. \end{cases}$$


定义算法映射：

$$B(x) = \begin{cases} \left[ \frac{1}{2}(x+3), \frac{1}{3}(2x+3) \right] & x \geq 3; \\ \frac{1}{3}(2x+1) & x < 3. \end{cases}$$

取点列  $x^{(k)} = 3 - \frac{1}{k}, y^{(k)} = \frac{7}{3} - \frac{2}{3k} \in B(x^{(k)})$ , 当  $x^{(k)} \rightarrow \bar{x} = 3$

时,  $y^{(k)} \rightarrow \bar{y} = \frac{7}{3} \notin B(\bar{x}) = B(3)$ , 所以  $B(x)$  在  $\bar{x} = 3$  处非闭。

当  $B(x)$  用于迭代过程时, 对于任意初始点  $x^{(1)}$ , 按照  $x^{(k+1)} \in B(x^{(k)})$  产生的迭代序列收敛于不同的集合: 若  $x^{(1)} \in (-\infty, 3)$ , 则算法产生的点列收敛于1; 若  $x^{(1)} \in [3, \infty)$ , 则算法产生的点列收敛于3。




## 合成映射(**composition mapping**)

**定义：**设 $X$ ， $Y$ 和 $Z$ 分别是空间 $E^n$ ， $E^p$ 和 $E^q$ 中的非空闭集，集值映射 $A: X \rightarrow 2^Y$ 和 $B: Y \rightarrow 2^Z$ 。若集值映射 $C: X \rightarrow 2^Z$ 定义如下：

$$\forall x \in X, \quad C(x) = \bigcup_{y \in A(x)} B(y),$$

则称 $C$ 是 $A$ 和 $B$ 的合成映射，记为 $C = BA$ 。



定理：给定集值映射  $A: X \rightarrow 2^Y, B: Y \rightarrow 2^Z$ ，假设  $A$  在点  $x \in X$  是闭的， $B$  在  $A(x)$  上是闭的。对于  $x^{(k)} \rightarrow x$ ，若  $y^{(k)} \in A(x^{(k)})$ ，并且  $\{y^{(k)}\}$  存在收敛子列  $\{y^{(k_j)}\}$ ，则合成映射  $C = BA$  在点  $x$  是闭的。

证明：给定  $x^{(k)} \in X, z^{(k)} \in C(x^{(k)})$ ，假设  $x^{(k)} \rightarrow x, z^{(k)} \rightarrow z$ 。

由合成映射定义，对于  $k = 1, 2, \dots$ ，存在  $y^{(k)} \in A(x^{(k)})$ ，使得  $z^{(k)} \in B(y^{(k)})$ 。

$\because \{y^{(k)}\}$  存在收敛子列  $\{y^{(k_j)}\}$ ，记  $\lim_{j \rightarrow +\infty} y^{(k_j)} = y$ 。

根据映射  $A$  的闭性，有  $y \in A(x)$ 。

根据映射  $B$  的闭性，有  $\lim_{j \rightarrow +\infty} z^{(k_j)} = z \in B(y)$ 。

$\because B(y) \subseteq C(x), \therefore z \in C(x) \Rightarrow C$  在点  $x$  是闭的。

**推论 1** 给定集值映射  $A: X \rightarrow 2^Y, B: Y \rightarrow 2^Z$ , 假设  $A$  在点  $x \in X$  是闭的,  $B$  在  $A(x)$  上是闭的。若  $Y$  是紧集, 则合成映射  $C = BA$  在点  $x$  是闭的。

**推论 2** 给定映射  $A: X \rightarrow Y$  ( $A$  是点到点的映射),  $B: Y \rightarrow 2^Z$ , 假设  $A$  在点  $x \in X$  连续,  $B$  在  $A(x)$  上是闭的, 则合成映射  $C = BA$  在点  $x$  是闭的。

## 算法收敛问题

定义：设 $\Omega$ 为解集合， $A: X \rightarrow 2^X$ 为算法映射。给定一个集合 $Y \subset X$ ，若对于任意的初始点 $x^{(1)} \in Y$ ，算法映射 $A$ 所产生的序列 $\{x^{(k)}\}$ 中任一收敛子序列的极限都属于 $\Omega$ ，则称算法映射 $A$ 在 $Y$ 上收敛。

若集合 $Y$ 是任意选取的（该集合不必限定在解集合 $\Omega$ 的很小领域内），则相应的收敛性称为全局收敛性 (*global convergence*). 若集合 $Y$ 只能取接近 $\Omega$ 的点集，则相应的收敛性称为局部收敛性 (*local convergence*).

# 全局收敛定理

**定理:** 设 $A$ 为 $X$ 上的一个算法,  $\Omega$ 为解集合, 给定

初点 $x^{(1)} \in X$ , 进行如下迭代:

若 $x^{(k)} \in \Omega$ , 则停止迭代; 否则, 令 $x^{(k+1)} \in A(x^{(k)})$ ,  
用 $k+1$ 代替 $k$ , 重复该过程。

如果下面的条件成立:

1. 序列 $\{x^{(k)}\}$ 含于 $X$ 的某个紧子集中;
2. 存在一个连续函数 $\alpha$ , 它是关于 $\Omega$ 和 $A$ 的下降函数;
3. 映射 $A$ 在 $\Omega$ 的补集上是闭的。

则序列 $\{x^{(k)}\}$ 的任一收敛子序列的极限属于 $\Omega$ 。



证明：首先证明序列  $\{\alpha(x^{(k)})\}$  有极限。

$\because$  序列  $\{x^{(k)}\}$  包含在某个紧子集内，所以存在收敛子列  $\{x^{(k_j)}\}$ ，记其极限为  $x$ ，由于  $\alpha(x)$  是连续的，

$$\therefore \lim_{j \rightarrow +\infty} \alpha(x^{(k_j)}) = \alpha(x).$$

$\because \alpha(x)$  是下降函数，

$$\therefore \lim_{k \rightarrow +\infty} \alpha(x^{(k)}) = \alpha(x).$$

利用反证法证明  $x \in \Omega$ .

假设某个收敛子序列  $\{x^{(k_j)}\}$  的极限  $x \notin \Omega$ ,

则考虑序列  $\{x^{(k_j+1)}\}$ , 它也存在收敛的子序列,

不妨设  $\lim_{j \rightarrow +\infty} x^{(k_j+1)} = \bar{x}$ , 则  $\bar{x} \in X$ .

$\because \alpha(x)$  连续,  $\therefore \lim_{j \rightarrow +\infty} \alpha(x^{(k_j+1)}) = \alpha(\bar{x})$ ,

根据极限的唯一性, 有  $\alpha(\bar{x}) = \alpha(x)$ 。

$\because x^{(k_j+1)} \in A(x^{(k_j)}), x^{(k_j)} \rightarrow x, x^{(k_j+1)} \rightarrow \bar{x}$

由于算法  $A$  在  $\Omega$  的补集上是闭的,  $x \notin \Omega$


$\therefore A$  在  $x$  处是闭的  $\Rightarrow \bar{x} \in A(x)$

由于  $\alpha$  是关于  $\Omega$  和  $A$  的下降函数,  $x \notin \Omega$ ,

$\therefore \alpha(\bar{x}) < \alpha(x)$  矛盾。

考虑如下算法

$$A(x) = \begin{cases} \frac{1}{2}(x-1)+1 & x > 1 \\ \frac{1}{2}x & x \leq 1 \end{cases}$$



解集合  $\Omega = \{0\}$

$\alpha(x) = |x|$  是关于解集合和  $A(x)$  的下降函数

从  $x > 1$  开始，算法产生一个收敛于  $1 \notin \Omega$  的序列

原因： $A$  在解集合外面不是闭的。

## 实用收敛准则

1.  $\|x^{(k+1)} - x^{(k)}\| < \varepsilon$  或者  $\frac{\|x^{(k+1)} - x^{(k)}\|}{\|x^{(k)}\|} < \varepsilon.$
2.  $f(x^{(k)}) - f(x^{(k+1)}) < \varepsilon$  或者  $\frac{f(x^{(k)}) - f(x^{(k+1)})}{|f(x^{(k)})|} < \varepsilon.$
3.  $\|\nabla f(x^{(k)})\| < \varepsilon$  (无约束最优化中).

## 收敛速率

定义： 设序列  $\{\gamma^{(k)}\}$  收敛于  $\gamma^*$ ，定义满足

$$\overline{\lim}_{k \rightarrow +\infty} \frac{\|\gamma^{(k+1)} - \gamma^*\|}{\|\gamma^{(k)} - \gamma^*\|^p} = \beta < \infty$$

的非负数  $p$  的上确界为序列  $\{\gamma^{(k)}\}$  的收敛级。

若序列的收敛级为  $p$ ，则称序列是  $p$  级收敛的。

若  $p = 1$  且  $\beta < 1$ ，则称序列是以收敛比  $\beta$  线性收敛的。

若  $p > 1$ ，或者  $p = 1$  且  $\beta = 0$ ，则称序列是超线性收敛的。

收敛级  $p$  越大，序列收敛得越快；当收敛级  $p$  相同时，收敛比  $\beta$  越小，序列收敛得越快。

例:  $\{a^k\} \quad 0 < a < 1$

$$\because \lim_{k \rightarrow \infty} a^k = 0$$

$$\text{又 } \lim_{k \rightarrow \infty} \frac{a^{k+1}}{a^k} = a < 1, \text{ 且 } \lim_{k \rightarrow \infty} \frac{a^{k+1}}{(a^k)^r} = \infty (\text{当 } r > 1 \text{ 时}),$$

$\therefore \{a^k\}$  以收敛比  $a$  线性收敛于 0。

例:  $\{a^{2^k}\} \quad 0 < |a| < 1$

$$\because \lim_{k \rightarrow \infty} a^{2^k} = 0$$

$$\text{又 } \lim_{k \rightarrow \infty} \frac{a^{2^{k+1}}}{(a^{2^k})^2} = \lim_{k \rightarrow \infty} \frac{a^{2^{k+1}}}{a^{2^{k+1}}} = 1, \text{ 且 } \lim_{k \rightarrow \infty} \frac{a^{2^{k+1}}}{(a^{2^k})^r} = \infty (\text{当 } r > 2 \text{ 时}),$$

$\therefore \{a^{2^k}\}$  是 2 级收敛的。

例:  $\left\{ \left( \frac{1}{k} \right)^k \right\}$

$$\therefore \lim_{k \rightarrow \infty} \left( \frac{1}{k} \right)^k = 0$$

$$\text{又 } \lim_{k \rightarrow \infty} \frac{\left( \frac{1}{k+1} \right)^{k+1}}{\left( \frac{1}{k} \right)^k} = \lim_{k \rightarrow \infty} \left( \frac{k}{k+1} \right)^k \times \frac{1}{k+1} = 0$$

$$\lim_{k \rightarrow \infty} \frac{\left( \frac{1}{k+1} \right)^{k+1}}{\left( \left( \frac{1}{k} \right)^k \right)^p} = \lim_{k \rightarrow \infty} \left( \frac{k}{k+1} \right)^{k+1} \times \frac{k^{(p-1)k}}{k} = \infty (p > 1)$$

$$\therefore \left\{ \left( \frac{1}{k} \right)^k \right\} \text{ 是超线性收敛的。}$$

# 算法的二次终止性

- 定义：若某个算法对于任意的正定二次函数，从任意的初始点出发，都能经有限步迭代达到其极小点，则称该算法具有二次终止性。



- 用二次终止性作为判断算法优劣的原因：
- **(1)** 正定二次函数具有某些较好的性质，因此一个好的算法应能够在有限步内达到其极小点。
- **(2)** 对于一个一般的目标函数，若在其极小点处的**Hesse**矩阵正定，由于

$$f(x) = f(x^*) + \nabla f(x^*)^T (x - x^*) + \frac{1}{2} (x - x^*)^T \nabla^2 f(x^*) (x - x^*) + o(\|x - x^*\|)$$

- 因此可以猜想，对正定二次函数好的算法，对于一般目标函数也应具有较好的性质。