

- 考试时间:
- **2020年1月6日晚上7: 00—9: 00**
- 考试地点:
- 一教**104: 2016010752~2019210931**
- 一教**201: 2019210932~2019310660**
- 一教**205: 2019310664~2019380018**及旁听生、进修生

- 答疑时间:
- **2020年1月5日上午9: 00—11: 30**
- **2016年1月5日下午2: 30—5: 00**
- 答疑地点: **6教6B103**

- **1.**携带研究生证，以备查对。
- **2.**提前十分钟进入考场。考试开始十五分钟后，不准再进入考场，逾时以旷考论。题卷发出十五分钟后，方可交卷离场。
- **3.**除答卷必需用的文具及教师指定的考试用具外，书包、书籍、笔记、纸张等一律按监考教师要求集中放置。
- **4.**不允许携带具有信息传递或存储功能的工具（如手机等）进入考场。
- **5.**答卷一般用钢笔或圆珠笔（蓝色或黑色，不得用红色），不得用铅笔（画图或外语考试选择题等指定用铅笔除外）。
- **6.**答卷时不准互借文具（包括计算器、计算尺等）。
- **7.**严禁以任何理由左顾右盼、交头接耳、抄袭或看别人答卷等各种形式的作弊行为。
- **8.**答卷时，不得中途离场后再行返回。如有特殊原因需离场者，必须经监考教师准许。答卷一经考生带出考场，即行作废。
- **9.**在规定的时间内答卷，不得拖延。交卷时间到，考生须在原座位安静地等候监考教师收卷后，方可离场。

# 总复习

- 一. 凸集与凸函数
- **1.** 凸集的定义、性质

设 $S_1$ 和 $S_2$ 是两个凸集,  $\beta$ 实数, 则

- (1)  $\beta S_1 = \{\beta x \mid x \in S_1\}$ 是凸集;
- (2)  $S_1 + S_2 = \{x^{(1)} + x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 是凸集;
- (3)  $S_1 - S_2 = \{x^{(1)} - x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 是凸集;
- (4)  $S_1 \cap S_2$ 是凸集;

## 2. 极点和极方向的定义

设 $S$ 是非空集合,  $x \in S$ , 若 $x$ 不能表示成 $S$ 中两个不同点的凸组合, 即若假设 $x = \lambda x^{(1)} + (1 - \lambda)x^{(2)}$ , 必推出 $x = x^{(1)} = x^{(2)}$ , 则称 $x$ 是凸集 $S$ 的极点。

**要求: 会证明或判断一个点是否是极点.**

设 $S$ 是闭凸集,  $d$ 为非零向量, 如果对 $S$ 中的每一个 $x$ , 有 $\{x + \lambda d \mid \lambda \geq 0\} \subset S$ , 则称 $d$ 是 $S$ 的方向; 又设 $d^{(1)}$ 和 $d^{(2)}$ 是 $S$ 的两个方向, 若对任何正数 $\lambda$ , 有 $d^{(1)} \neq \lambda d^{(2)}$ , 则称 $d^{(1)}$ 和 $d^{(2)}$ 是两个不同的方向, 若 $S$ 的方向 $d$ 不能表示成该集合的两个不同方向的正的线性组合, 则称 $d$ 为 $S$ 的极方向。

要求：会证明或判断一个非零向量是否是方向或极方向。

结论： 设 $S = \{x \mid Ax = b, x \geq 0\}$ 为非空集合， $d$ 是非零向量，则 $d$ 是 $S$ 的方向的充要条件是 $d \geq 0$ 且 $Ad = 0$ 。

了解表示定理

## 2. 凸集分离定理

(1) 会应用凸集分离定理

(2) 掌握**Farkas**定理和**Gordan**定理和证明方法，  
会应用这两个定理证明相应的题目。

**Farkas定理：** 设 $A$ 为 $m \times n$ 矩阵， $c$ 为 $n$ 维列向量，则  
 $Ax \leq 0, c^T x > 0$ 有解的充要条件是 $A^T y = c, y \geq 0$ 无解。

**Gordan定理：** 设 $A$ 为 $m \times n$ 矩阵，那么 $Ax < 0$ 有解的  
充要条件是不存在非零向量 $y \geq 0$ ，使得 $A^T y = 0$ 。

### 3. 凸函数(凹函数)

要求：掌握凸(凹)函数的定义、性质及判断方法，会证明或判断一个函数是否是凸(凹)函数。

**凸函数**：设 $S$ 是 $E^n$ 中的非空凸集， $f(x)$ 是定义在 $S$ 上的实函数，如果对于每一对 $x_1, x_2 \in S$ 及每一个 $a, 0 \leq a \leq 1$ , 都有

$$f(ax_1 + (1-a)x_2) \leq af(x_1) + (1-a)f(x_2)$$

则称函数 $f(x)$ 为 $S$ 上的凸函数。上式中，若 $\leq$ 变为 $<$ ，则称为严格凸函数。

若 $-f(x)$ 为 $S$ 的凸函数，则称 $f(x)$ 为 $S$ 上的**凹函数**。

# 凸函数性质

(1) 设 $f_1(x)$ ,  $f_2(x)$ 是凸集 $S$ 上的凸函数, 则函数 $f_1(x)+f_2(x)$ 在 $S$ 上也是凸函数。

(2) 设 $f(x)$ 是凸集 $S$ 上的凸函数, 则对任意的 $a \geq 0$ , 函数 $af(x)$ 是凸的。

推广: 设 $f_1(x)$ ,  $f_2(x)$ , ...,  $f_k(x)$ 是凸集 $S$ 上的凸函数,  $a_i \geq 0$ , 则 $a_1f_1(x)+a_2f_2(x)+\dots+a_kf_k(x)$ 也是凸集 $S$ 上的凸函数。

(3) 设 $f(x)$ 是凸集 $S$ 上的凸函数, 对每一个实数 $c$ , 则集合

$$S_c = \{x \mid x \in S, f(x) \leq c\} \text{ 是凸集。}$$



**定理(一阶充要条件):** 设 $S$ 是 $E^n$ 中非空开凸集,  $f(x)$ 是定义在 $S$ 上的可微函数, 则 $f(x)$ 为凸函数的充要条件是对任意两点 $x^{(1)}, x^{(2)} \in S$ , 有

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)});$$

$f(x)$ 为严格凸函数的充要条件是对任意互不相同两点 $x^{(1)}, x^{(2)} \in S$ , 有

$$f(x^{(2)}) > f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}).$$

**定理(二阶充要条件):** 设 $S$ 是 $E^n$ 中非空开凸集,  $f(x)$ 是定义在 $S$ 上的二次可微函数, 则 $f(x)$ 为凸函数的充要条件是对任意 $x \in S$ ,  $f(x)$ 在 $x$ 处的Hessian矩阵 $\nabla^2 f(x)$ 是半正定的。

# 凸规划

- 凸规划：求凸函数在凸集上的极小点。

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, i = 1, \dots, m \\ & h_j(x) = 0, j = 1, \dots, l \end{aligned}$$

若 $f(x)$ 是凸函数， $g_i(x)(i = 1, \dots, m)$ 是凹函数， $h_j(x)(j = 1, \dots, l)$ 是线性函数，则原问题为凸规划。

性质：凸规划的局部极小点就是整体极小点，且极小点的集合为凸集。

要求：会判断一个模型是否为凸规划

# 线性规划部分

## LP的标准形式

- 1、极小化型
- 2、约束方程为等式
- 3、所有的决策变量为非负值
- 4、约束方程的右端项系数为非负值

$$\min z = \sum_{j=1}^n c_j x_j$$

$$\begin{aligned} s.t. \quad & \sum_{j=1}^n a_{ij} x_j = b_i \quad i=1, \dots, m \\ & x_j \geq 0 \quad j=1, \dots, n \end{aligned}$$

$$\begin{aligned} \min \quad & z = cx \quad c_{1 \times n} \\ s.t. \quad & Ax = b \quad A_{m \times n} \quad b_{m \times 1} \geq 0 \\ & x \geq 0 \quad x_{n \times 1} \end{aligned}$$

- **1. 基本概念:**
- 可行域(线性规划的可行域是凸集).
- 解的情形:无解(无可行解)、无界解(不存在有限的最优解)、最优解(最优解与最优值的区别)、局部最优解与全局最优解.
- 可行解、基本解、基、基变量、非基变量、基本可行解、非退化(退化)的基本可行解。

- **2. 基本性质:**
- 线性规划存在有限最优解的充要条件是所有 $cd^{(i)}$ 为非负数, 其中 $d^{(i)}$ 为可行域的极方向。
- 若线性规划问题存在有限最优解, 则目标函数的最优值可在某个极点达到。
- 基本可行解与可行域极点之间的关系---等价。
- 基本可行解的存在问题: 有可行解, 一定有基本可行解。

# 单纯形法

$$\begin{cases} \min & f(x) = cx \\ s.t. & Ax = b \\ & x \geq 0 \end{cases}$$

1. 存在初始基 $B$ , 使得 $B^{-1}b \geq 0$ .

如何判断该问题是否有最优解?

如何判断一个基是否为最优基?

如何判断该问题是否有无穷多最优解?

用单纯形表求解问题：

	$x_B$	$x_N$	右端
$x_B$	$I_m$	$B^{-1}N$	$B^{-1}b$
	0	$c_B B^{-1}N - c_N$	$c_B B^{-1}b$

假设  $\bar{b} = B^{-1}b \geq 0$ , 有一基本可行解

$$x = \begin{pmatrix} x_B \\ x_N \end{pmatrix} = \begin{pmatrix} B^{-1}b \\ 0 \end{pmatrix}$$

(1) 若  $c_B B^{-1}N - c_N \leq 0$  (极小化问题), 则现行基本可行解为最优解

(2) 若存在  $c_B B^{-1}P_j - c_j > 0$ , 用 **主元消去法** 求改进的基本可行解

## 2. 寻找初始基本可行解

$$\begin{cases} \min & f(x) = cx \\ s.t. & Ax = b \\ & x \geq 0 \end{cases}$$

两阶段法

$$\begin{cases} \min & e^T x_a \\ s.t. & Ax + x_a = b \quad e = (11 \cdots 1)^T \\ & x, x_a \geq 0 \end{cases}$$

大M法

$$\begin{cases} \min & cx + Me^T x_a \\ s.t. & Ax + x_a = b \quad e = (11 \cdots 1)^T_{m \times 1} \quad M > 0 \\ & x \geq 0 \end{cases}$$



# 对偶原理

	min	max	
• 变量	$\geq 0$	$\leq$	约束 方程
• 量	$\leq 0$	$\geq$	
•	无限制	$=$	
•			
• 约束	$\geq$	$\geq 0$	变 量
• 束	$\leq$	$\leq 0$	
• 方	$=$	无限制	
• 程			

- 会写各种形式（对称、非对称、一般形式）的对偶问题；
- 掌握弱对偶定理和强对偶定理及其相关推论；
- 会用互补松弛定理求原问题或对偶问题的解；

# 小结

原问题(min)

对应关系

对偶问题(max)

有最优解




有最优解

无界解



不可行

不可行



无界解

# 对偶单纯形法

- 掌握对偶单纯形方法（对偶可行的基本解，如何求初始对偶可行的基本解）。
- 与原单纯形法的区别：
- 原单纯形法保持原问题的可行性，对偶单纯形法保持所有检验数  $wP_j - c_j \leq 0$ ，即保持对偶问题的可行性。
- 特点：先选择出基变量，再选择进基变量。

- **5. 灵敏度分析**
- 改变非基变量和基变量价格系数后，原问题最优解和最优值的改变，会求最优解不变时价格系数的变化范围；
- 右端向量改变对最优解及最优值的影响，会求最优基不变时，右端向量的变化范围；
- 会判断增加新的约束后，原问题最优解是否发生变化

# 最优性条件

- 无约束问题的极值条件:

定理1:(一阶必要条件)设函数 $f(x)$ 在点 $\bar{x}$ 处可微, 若 $\bar{x}$ 是局部极小点, 则 $\nabla f(\bar{x}) = 0$ .

定理2:(二阶必要条件)设 $f(x)$ 在 $\bar{x}$ 处二阶可微, 若 $\bar{x}$ 是局部极小点, 则 $\nabla f(\bar{x}) = 0$ , 且 $Hessian$ 矩阵 $\nabla^2 f(\bar{x})$ 是半正定的。

定理3: 设函数 $f(x)$ 在点 $\bar{x}$ 处二次可微, 若梯度 $\nabla f(\bar{x}) = 0$ , 且 $Hessian$ 矩阵 $\nabla^2 f(\bar{x})$ 正定, 则 $\bar{x}$ 是严格局部极小点。

推论：对于正定二次函数 $f(x) = \frac{1}{2}x^T Ax + b^T x + c$

( $A$ 对称正定)，有唯一极小点 $x^* = -A^{-1}b$ .

定理4：设 $f(x)$ 是定义在 $E^n$ 上的可微凸函数， $\bar{x} \in E^n$ ，  
则 $\bar{x}$ 为整体极小点的充要条件是 $\nabla f(\bar{x}) = 0$ .

# 约束极值问题的最优性条件

对  $\min_{x \in E^n} f(x)$ , 设  $\bar{x} \in E^n$  是任给一点,

$d \neq 0$ , 若存在  $\delta > 0$ , 使得对任意的  $\lambda \in (0, \delta)$ , 有  $f(\bar{x} + \lambda d) < f(\bar{x})$ , 则称  $d$  为  $f(x)$  在点  $\bar{x}$  处的下降方向 (descent direction)。

$$F_0 = \left\{ d \mid \nabla f(\bar{x})^T d < 0 \right\}$$

称为点  $\bar{x}$  处的下降方向集。



**定义：** 设集合  $S \subset E^n$ ,  $\bar{x} \in clS$ ,  $d$  为非零向量, 若存在数  $\delta > 0$ , 使得对任意  $\lambda \in (0, \delta)$ , 都有

$$\bar{x} + \lambda d \in S$$

则称  $d$  为集合  $S$  在  $\bar{x}$  的可行方向 (feasible direction)。

$$D = \left\{ d \mid d \neq 0, \bar{x} \in clS, \exists \delta > 0, \forall \lambda \in (0, \delta), \text{有 } \bar{x} + \lambda d \in S \right\}$$

$\bar{x}$  处的可行方向锥。

**定理:** 设 $x$ 是问题 $(A)$ 的可行解,  $I = \{i \mid g_i(x) = 0\}$ 是在 $x$ 处起作用约束下标集, 又设 $f(x)$ ,  $g_i(x)(i \in I)$ 在 $x$ 处可微,  $g_i(x)(i \notin I)$ 在 $x$ 处连续, 如果  $\nabla f(x)^T d < 0$ ,  $\nabla g_i(x)^T d > 0(i \in I)$ , 则 $d$ 是可行下降方向。

$$(A) \quad \begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, 2, \dots, m \end{cases}$$

其中 $f(x), g_i(x)$ 均为可微函数。

定理2(KKT必要条件) 考虑问题 
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 $\bar{x}$ 为可行点,  $I = \{i \mid g_i(\bar{x}) = 0\}$ .  $f, g_i (i \in I)$ 在 $\bar{x}$ 处可微,  
 $g_i (i \notin I)$ 在 $\bar{x}$ 连续,  $h_j (j = 1, \dots, l)$ 在 $\bar{x}$ 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关, 若 $\bar{x}$ 是局部最优解, 则存在数 $w_i, i \in I$   
 和 $v_j (j = 1, \dots, l)$ , 使得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0.$$

$$w_i \geq 0 \quad (i \in I).$$

定理2'(KKT必要条件) 考虑问题 
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 $\bar{x}$ 为可行点,  $I = \{i \mid g_i(\bar{x}) = 0\}$ .  $f, g_i$ 在 $\bar{x}$ 处可微,  $h_j (j = 1, \dots, l)$ 在 $\bar{x}$ 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关, 若 $\bar{x}$ 是局部最优解, 则存在数 $w_i, i \in I$ 和 $v_j (j = 1, \dots, l)$ , 使得

$$\nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0$$

$$w_i g_i(\bar{x}) = 0, i = 1, 2, \dots, m$$

$$w_i \geq 0 \quad i = 1, 2, \dots, m.$$

## 定义广义的**Lagrange**函数:

$$\begin{aligned} L(x, w, v) &= f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x) \\ &= f(x) - w^T g(x) - v^T h(x) \end{aligned}$$

其中  $w = (w_1, w_2, \dots, w_m)^T$

$v = (v_1, v_2, \dots, v_l)^T$

乘子向量

$g(x) = (g_1(x), \dots, g_m(x))^T$

$h(x) = (h_1(x), \dots, h_l(x))^T.$

定理2'(KKT必要条件) 考虑问题 
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 $\bar{x}$ 为可行点,  $I = \{i \mid g_i(\bar{x}) = 0\}$ .  $f, g_i$ 在 $\bar{x}$ 处可微,  $h_j (j = 1, \dots, l)$ 在 $\bar{x}$ 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关, 若 $\bar{x}$ 是局部最优解, 则存在乘子向量 $\bar{w} \geq 0, \bar{v}$ , 使得

$$\nabla_x L(\bar{x}, \bar{w}, \bar{v}) = 0$$

### 定理3.(一阶充分条件)

$$\text{设问题} \begin{cases} \min f(x) \\ \text{s.t. } g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$

中,  $f$ 是凸函数,  $g_i (i = 1, 2, \dots, m)$ 是凹函数,  
 $h_j (j = 1, 2, \dots, l)$ 是线性函数,  $S$ 为可行域,  
 $\bar{x} \in S$ ,  $I = \{i \mid g_i(\bar{x}) = 0\}$ 。  $f$ 和 $g_i (i \in I)$ 在点 $\bar{x}$ 可微,  
 $h_j (j = 1, 2, \dots, l)$ 在点 $\bar{x}$ 连续,  $g_i (i \notin I)$ 在点 $\bar{x}$ 连续,  
且在 $\bar{x}$ 处 $KKT$ 条件成立, 则 $\bar{x}$ 为整体极小点。

定理（二阶必要条件）：设 $\bar{x}$ 是 $(NP)$ 的局部最优解， $f, g_i (i = 1, \dots, m)$ 和 $h_j (j = 1, \dots, l)$ 二次连续可微，且在 $\bar{x}$ 处， $\{\nabla g_i(\bar{x}), i \in I, \nabla h_j(\bar{x}), j = 1, \dots, l\}$ 为线性无关组，则存在 $\bar{w}, \bar{v}$ ，使 $(\bar{x}, \bar{w}, \bar{v})$ 为 $(LM)$ 的解且矩阵 $\nabla^2 L_x(\bar{x}, \bar{w}, \bar{v})$ 在子空间 $\bar{G}$ 上是半正定的，其中

$$\bar{G} = \left\{ d \left| \begin{array}{l} \nabla g_i(\bar{x})^T d = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ \nabla g_i(\bar{x})^T d \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l \end{array} \right. \right\}.$$



定理（二阶充分条件）：设 $f, g_i(i=1, \dots, m)$ 和 $h_j(j=1, \dots, l)$ 是二次连续可微函数， $\bar{x}$ 为可行解，若存在 $\bar{w}, \bar{v}$ ，使 $(\bar{x}, \bar{w}, \bar{v})$ 为 $(LM)$ 的解且矩阵 $\nabla^2 L_x(\bar{x}, \bar{w}, \bar{v})$ 在子空间 $G$ 上是正定的，则 $\bar{x}$ 是严格局部极小点。

其中

$$G = \left\{ d \neq 0 \left| \begin{array}{l} \nabla g_i(\bar{x})^T d = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ \nabla g_i(\bar{x})^T d \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l \end{array} \right. \right\}.$$

## 对偶问题（要求：会写对偶问题）

### Lagrange对偶问题

$$\min f(x)$$

$$s.t. \quad g_i(x) \geq 0, i = 1, \dots, m$$

$$h_j(x) = 0, j = 1, \dots, l$$

$$x \in D$$

(1)

定义(1)的对偶问题：

$$\max \theta(w, v)$$

(2)

$$s.t. \quad w \geq 0$$

$$\text{其中 } \theta(w, v) = \inf \left\{ f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x) \mid x \in D \right\}$$

若上式不存在有限下界时，令  $\theta(w, v) = -\infty$ .

$\theta(w, v)$ 称为Lagrange对偶函数。

## 定理1(弱对偶定理)

设 $x$ 和 $(w, v)$ 分别是原问题和对偶问题的可行解, 则

$$f(x) \geq \theta(w, v).$$

**推论1:** 对于原问题和对偶问题, 必有

$$\inf\{f(x) \mid g(x) \geq 0, h(x) = 0, x \in D\} \geq \sup\{\theta(w, v) \mid w \geq 0\}.$$

**推论2:** 若 $f(\bar{x}) \leq \theta(\bar{w}, \bar{v})$ , 其中 $\bar{x}$ 为原问题的可行解,  $\bar{w} \geq 0$ , 则 $\bar{x}$ 和 $(\bar{w}, \bar{v})$ 分别是原问题和对偶问题的最优解。

**推论3:** 若 $\inf\{f(x) \mid g(x) \geq 0, h(x) = 0, x \in D\} = -\infty$ , 则对 $\forall w \geq 0$ , 有 $\theta(w, v) = -\infty$ 。

**推论4:** 如果 $\sup\{\theta(w, v) \mid w \geq 0\} = +\infty$ , 则原问题没有可行解。

# 算法

- 闭映射的定义
- 会判断一个具体的算法映射在某个点是否具有闭的性质。
- 二次终止性的定义：若某个算法对于任意的正定二次函数，从任意的初始点出发，都能经有限步迭代达到其极小点，则称该算法具有二次终止性。

# 一维搜索

- 一维搜索的定义
- 一维搜索的性质:

设目标函数 $f(x)$ 具有一阶偏导数,  $x^{(k+1)}$ 由下列规则产生:

$$\begin{cases} f(x^{(k)} + \lambda_k d^k) = \min_{\lambda} f(x^{(k)} + \lambda d^k) \\ x^{(k+1)} = x^{(k)} + \lambda_k d^k \end{cases}$$

则有 $\nabla f(x^{(k+1)})^T d^k = 0$ 。

# 使用导数的最优化方法

- 最速下降方向的定义:

$$d^{(k)} = -\nabla f(x^{(k)})$$

- 牛顿方向:

$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

# 共轭方向法

## 共轭方向

**定义：** 设 $A$ 是 $n \times n$ 对称正定矩阵，若 $E^n$ 中的两个方向 $d^{(1)}$ 和 $d^{(2)}$ 满足

$$(d^{(1)})^T A d^{(2)} = 0$$

则称这两个方向关于 $A$ 共轭，或称它们关于 $A$ 正交。

## 性质

设 $A$ 是 $n$ 阶对称正定矩阵， $d^{(1)}, d^{(2)}, \dots, d^{(k)}$ 是 $k$ 个 $A$ 共轭的非零向量，则这 $k$ 个向量线性无关。

**定理2:** 设有二次函数

$$f(x) = \frac{1}{2} x^T A x + b^T x + c,$$

其中 $A_{n \times n}$ 是对称正定矩阵,  $d^{(0)}, d^{(1)}, \dots, d^{(n-1)}$ 是 $A$ 共轭的非零向量, 从任意一点 $x^{(0)} \in E^n$ 出发, 依次沿这组向量进行一维搜索,

$$\min_{\lambda \geq 0} f(x^{(k)} + \lambda d^{(k)}) = f(x^{(k)} + \lambda_k d^{(k)})$$

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)} \quad k = 0, 1, \dots, n-1$$

则 $\nabla f(x^{(k+1)})^T d^{(j)} = 0, j = 0, 1, \dots, k$ 。



## 定理（扩张子空间定理,expanding subspace theorem）

设有函数 
$$f(x) = \frac{1}{2} x^T A x + b^T x + c$$

其中 $A$ 为 $n$ 阶对称正定矩阵,  $d^{(1)}, d^{(2)}, \dots, d^{(k)}$ 是 $A$ 共轭的非零向量。以任意的 $x^{(1)} \in E^n$ 为初始点, 依次沿 $d^{(1)}, d^{(2)}, \dots, d^{(k)}$ 进行一维搜索, 得到点 $x^{(2)}, x^{(3)}, \dots, x^{(k+1)}$ , 则 $x^{(k+1)}$ 是 $f(x)$ 在线性流形

$$\begin{aligned} M_k \left( x^{(1)}; \{d^{(1)}, d^{(2)}, \dots, d^{(k)}\} \right) &= \left\{ x \left| x = x^{(1)} + \sum_{i=1}^k \mu_i d^{(i)}, \mu_i \in R \right. \right\} \\ &= x^{(1)} + B_k \end{aligned}$$

上的唯一极小点。特别的, 当 $k = n$ 时,  $x^{(n+1)}$ 是 $f(x)$ 在 $E^n$ 上的唯一极小点。

## 可行方向法:

$$\begin{cases} \min f(x) \\ s.t. \quad Ax \geq b \\ \quad \quad Ex = e \end{cases} \quad (1)$$

**定理:** 设 $\bar{x}$ 是问题(1)的可行解,在 $\bar{x}$ 点处,有

$$A_1 \bar{x} = b_1, A_2 \bar{x} > b_2$$

其中 $A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}$ ,  $b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$ , 则非零向量 $d$ 是 $\bar{x}$ 处的可行方向

的充要条件是 $A_1 d \geq 0, Ed = 0$ .

$$(2) \quad \begin{cases} \min \nabla f(x)^T d \\ s.t. \quad A_1 d \geq 0 \\ \quad \quad Ed = 0 \\ \quad \quad |d_j| \leq 1, j = 1, 2, \dots, n \end{cases}$$

在问题(1)中，设 $x$ 是可行解，在点 $x$ 处有

$A_1 x = b_1, A_2 x > b_2$ ，其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix},$$

则 $x$ 是 $KKT$ 点的充要条件是问题(2)的目标函数最优值  $= 0$ 。

**定理：** 设 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是子空间 $U$ 的一组基，记

$$M = \begin{bmatrix} \alpha_1^T \\ \alpha_2^T \\ \vdots \\ \alpha_r^T \end{bmatrix}_{r \times n}$$

则

(1)由 $E^n$ 到 $U$ 的正交投影矩阵 $Q$ 可表示为

$$Q = M^T (MM^T)^{-1} M。$$

(2)由 $E^n$ 到 $U^\perp$ 的正交投影矩阵 $P$ 可表示为

$$P = I - M^T (MM^T)^{-1} M。$$

**推论1:** 若 $Q$ 是正交投影矩阵, 则 $Q^T = Q$ ,  $QQ = Q$ .

**推论2:** 若 $Q$ 是正交投影矩阵, 则 $Q$ 是半正定的.

**定理:** 设 $x$ 是问题(1)的可行解, 在点 $x$ 处, 有 $A_1x = b_1$ ,  
 $A_2x > b_2$ , 其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

又设 $M = \begin{bmatrix} A_1 \\ E \end{bmatrix}$ 为满秩矩阵, 令

$$P = I - M^T (MM^T)^{-1} M$$

若 $P\nabla f(x) \neq 0$ , 令 $d = -P\nabla f(x)$ , 则 $d$ 为下降可行方向。

**定理2:** 设 $x$ 是问题(1)的可行解, 在点 $x$ 处, 有 $A_1x = b_1$ ,  
 $A_2x > b_2$ , 其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

又设 $M = \begin{bmatrix} A_1 \\ E \end{bmatrix}$ 为满秩矩阵, 令

$$P = I - M^T (MM^T)^{-1} M$$

$$W = (MM^T)^{-1} M \nabla f(x) = \begin{bmatrix} u \\ v \end{bmatrix}$$

其中 $u$ 和 $v$ 分别对应于 $A_1$ 和 $E$ 。设 $P \nabla f(x) = 0$ , 则

1. 若 $u \geq 0$ , 则 $x$ 为 $KKT$ 点;

2. 如果 $u$ 中含有负分量, 不妨设 $u_j < 0$ , 这时从 $A_1$ 中去掉 $u_j$ 对应的行, 得到 $\hat{A}_1$ 。令

$$\hat{M} = \begin{bmatrix} \hat{A}_1 \\ E \end{bmatrix} \quad \hat{P} = I - \hat{M}^T (\hat{M} \hat{M}^T)^{-1} \hat{M}$$

$$d = -\hat{P} \nabla f(x)$$

则 $d$ 为 $x$ 处的下降可行方向。

$$W = (MM^T)^{-1} M \nabla f(x) = \begin{bmatrix} u \\ v \end{bmatrix}$$

## Wolfe既约梯度法

$$\min f(x)$$

$$s.t. \quad Ax = b, \quad x \geq 0$$

$A_{m \times n}$ ,  $r(A) = m$ ,  $b_{m \times 1}$ ,  $f$  是  $E^n$  上的连续可微函数



$$A = (B, N), \quad x = \begin{pmatrix} x_B \\ x_N \end{pmatrix}$$

$$\min f(x_B, x_N)$$

$$s.t. \quad Bx_B + Nx_N = b$$

$$x_B, x_N \geq 0$$



$$\min F(x_N)$$

$$s.t. \quad x_B, x_N \geq 0$$

$$x_B = B^{-1}b - B^{-1}Nx_N$$

$$\Rightarrow F(x_N) = f(x_B(x_N), x_N)$$

$f(x)$ 的既约梯度为

$$r(x_N) = \nabla F(x_N)$$

$$= \nabla_{x_N} f(x) - (B^{-1}N)^T \nabla_{x_B} f(x)$$

**定理** 设 $x$ 是可行解,  $A = (B, N)$ 是 $m \times n$ 矩阵,  $B$ 为 $m$ 阶可逆矩阵,  $x = (x_B^T, x_N^T)^T$ ,  $x_B > 0$ , 函数 $f$ 在点 $x$ 处可微, 又设

$$d = \begin{pmatrix} -B^{-1}Nd_N \\ d_N \end{pmatrix},$$

其中 
$$d_{N_j} = \begin{cases} -x_{N_j} r_j(x_N) & r_j(x_N) > 0 \\ -r_j(x_N) & r_j(x_N) \leq 0 \end{cases}$$

如果 $d \neq 0$ , 则 $d$ 是下降可行方向, 而且 $d = 0$ 的充要条件是 $x$ 为 $KKT$ 点。

# 惩罚函数法

- 外点法的定义及相关性质。

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ \quad \quad h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$

$$\min F(x, \sigma) = f(x) + \sigma \left[ \sum_{i=1}^m \varphi[g_i(x)] + \sum_{j=1}^l \psi[h_j(x)] \right]$$

函数 $\varphi$ 和 $\psi$ 的典型取法:

$$\varphi[g_i(x)] = [\max\{0, -g_i(x)\}]^\alpha \quad \psi[h_j(x)] = |h_j(x)|^\beta$$

其中 $\alpha \geq 1, \beta \geq 1$ 均为给定常数, 通常取 $\alpha = \beta = 2$ 。

- 内点法的定义及性质

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \end{cases}$$

$$\begin{cases} \min G(x, r) = f(x) + rB(x) \\ s.t. \quad x \in \text{int } S \end{cases}$$

$$B(x) = \sum_{i=1}^m \frac{1}{g_i(x)} \quad B(x) = -\sum_{i=1}^m \ln g_i(x)$$